

Trabalho Prático 1 de AEDS3

Biblioteca do Filipe

Douglas Rodrigues de Almeida

douglasralmeida@live.com

1. Introdução

A necessidade de grande capacidade de memória aliada ao seu alto custo faz com que os computadores apresentem vários níveis de memória. A memória secundária, mais barata, possui grande capacidade de armazenamento, entretanto o custo para acessá-la é algumas ordens de grandeza menor que o custo de processamento da memória principal. Essa restrição leva a necessidade de algoritmos que façam ordenação e pesquisa de grandes quantidades de registros, maior que a capacidade da memória principal do computador, com a menor quantidade possível de acessos a memória secundária.

O objetivo deste trabalho é implementar um simulador de gerenciamento de biblioteca usando um computador com memória principal limitada. Para superar essa limitação, o aplicativo utiliza técnicas de ordenação e pesquisa que minimizam a quantidade de vezes que a memória secundária é acessada.

2. Implementação

Quicksort Externo

O quicksort é um algoritmo eficiente para ordenação em memória principal. Seu tempo de execução médio é $O(n \log n)$. A ideia básica do quicksort é dividir o problema de ordenar um conjunto de itens em problemas menores. Cada problema menor é ordenado de forma independente e os resultados combinados para produzir a solução do problema maior.

A ideia básica do quicksort foi adaptada para ordenação em memória secundária. Chamado de quicksort externo, o algoritmo utiliza um buffer na memória com capacidade de, pelo menos, 3 registros.

Seja um arquivo $A = \{R_1, \dots, R_n\}$ de n registros.

Seja R_i , $1 < i < n$, o registro que se encontra na i -ésima posição de A .

1) Particionar A na seguinte forma:

$\{R_1, \dots, R_i\} \leq R_{i+1} \leq R_{i+2} \leq \dots \leq R_{j-2} \leq R_{j-1} \leq \{R_j, \dots, R_n\}$

2) Chamar o algoritmo recursivamente para cada um dos subarquivos

$A_1 = \{R_1, \dots, R_i\}$ e $A_2 = \{R_j, \dots, R_n\}$

Código 1: Algoritmo do quicksort externo.

Inicialmente, são lidos para uma memória com capacidade de m registros, os primeiros e últimos $m/2$ registros da memória secundária onde são ordenados com algum algoritmo de ordenação interna. Os registros ordenados são armazenados de volta na memória secundária já na sua posição final, denominado pivô. O pivô possui o tamanho da memória principal. Todos os registros maiores que o maior registro do pivô são gravados à esquerda e todos os registros menores que o menor registro do pivô são gravados à direita. Logo depois, os lados esquerdos e direitos do pivô são

ordenados de forma recursiva. Essa operação se repete até que alcançar subconjuntos de um ou nenhum registro.

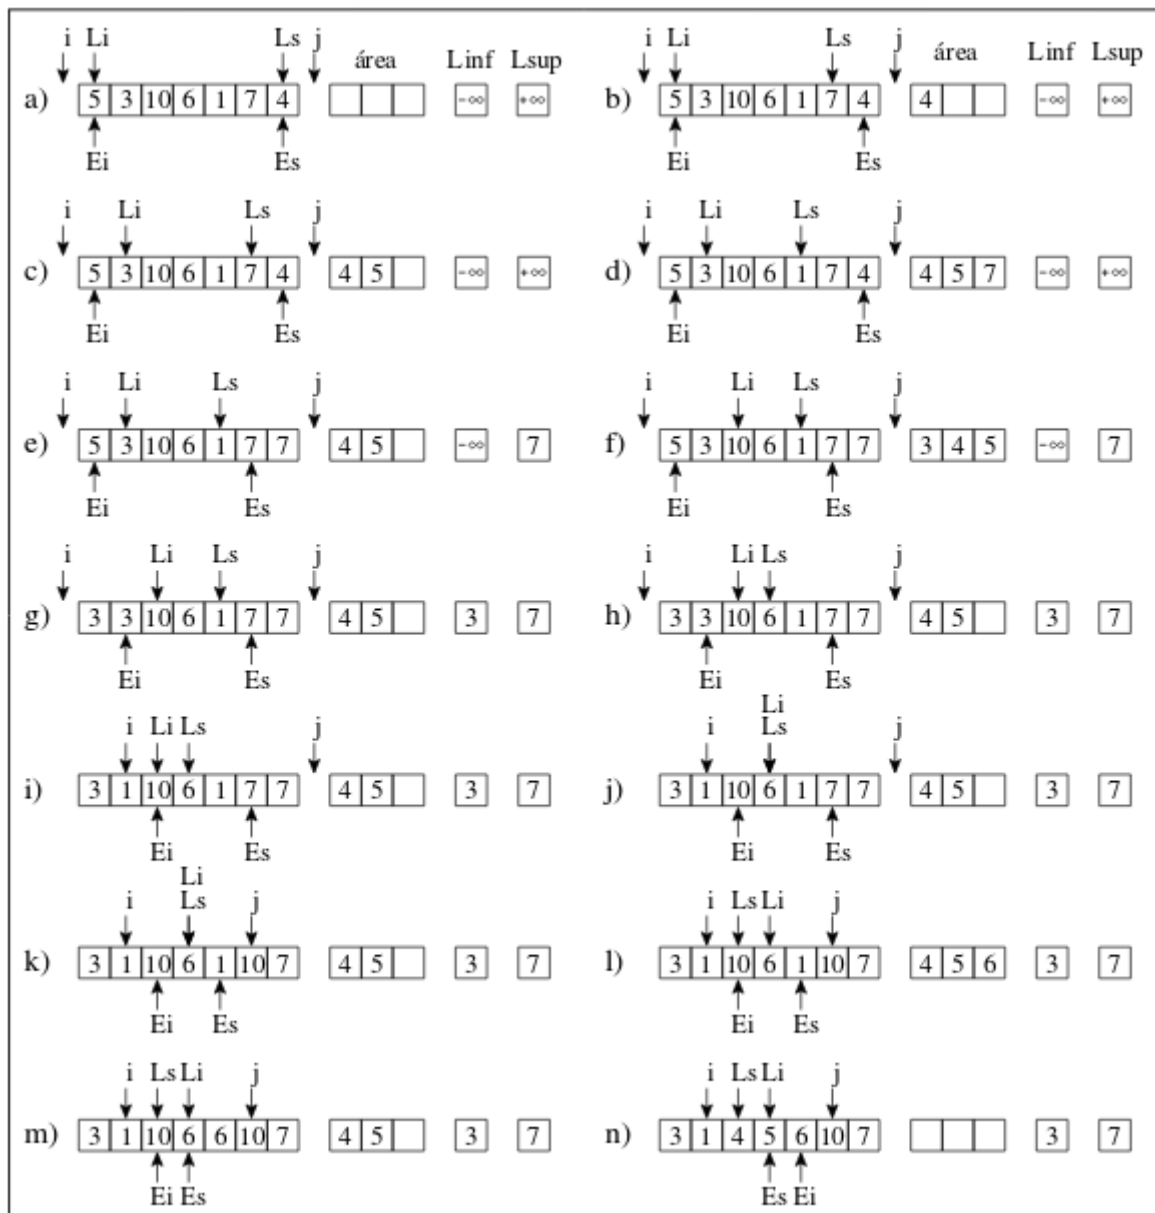


Figura 1: Processo de geração do pivô ordenado no Quicksort Externo

Árvore B

Árvores B de ordem m são árvores **m-árias** e balanceadas que são usadas para organizar grandes quantidades de registros armazenados em memória secundária. A árvore B permite acesso sequencial eficiente e, o custo para recuperar, inserir e remover registros é logarítmico. O espaço utilizado pelos dados é, pelo menos, 50% do espaço reservado.




Figura 2: Árvore B de ordem 1.

Uma árvore B de ordem m possui as seguintes características:

- Cada caminho da raiz até a folha da árvore possui o mesmo comprimento.
- Todos os nós da árvore, com exceção da raiz, possuem entre m e $2m$ registros. A raiz possui entre 1 e $2m$ registros.
- Cada nó tem entre $m+1$ e $2m+1$ filhos.
- Os registros armazenados no mesmo nó estão em ordem crescente.




Figura 3: Pesquisa a chave 53.

Por ser maior que 40, a pesquisa caminha para a subárvore da direita.

Os limites calculados por Comer para altura máxima e altura mínima de uma árvore B de ordem m contendo N registros são:

$$\log_{2m+1}(N+1) \leq \text{altura} \leq 1 + \log_{m+1}\left(\frac{N+1}{2}\right)$$

O procedimento de pesquisa de um registro na árvore B é recursivo. Primeiro compara-se sequencialmente a chave de pesquisa com as chaves da raiz em busca do intervalo compatível com o registro. Caminhamos, então, à subárvore correspondente ao intervalo e repetimos o processo até encontrarmos o registro procurado ou chegarmos a uma folha, no caso do registro não estiver na árvore.

A inserção de um registro na árvore B de ordem m ocorre da seguinte maneira:

- 1) A partir da raiz, procura-se o nó apropriado para inserir o registro.
- 2) Se o nó onde o registro será inserido tiver menos de $2m$ nós, insere o registro em ordem crescente neste nó.
- 3) Se o nó onde o registro será inserido tiver $2m$ nós, divide-se em dois, redistribuindo igualmente os registros entre os nós e promovendo o registro do meio para o nó pai.
- 4) Se o nó pai estiver cheio repete-se o procedimento do item anterior no nó pai.

Código 2: Algoritmo de inserção na árvore B.

No pior caso, a divisão pode propagar-se até a raiz aumentando a altura da árvore. A árvore B somente aumenta sua altura com a divisão da raiz.

Existem variações da árvore B, como árvore B* que otimiza o uso de memória e árvore B+ que facilita o acesso concorrente aos registros.

Um sistema com memória virtual pode diminuir o custo de pesquisa em árvores B. Dependendo do esquema de reposição de páginas implementado, a raiz da árvore, por exemplo, sempre estará na memória principal.

Sistema

O sistema foi desenvolvido em módulos que facilitam sua manutenção.

O TAD TArvoreB implementa uma árvore B para pesquisas conforme descrito nesta documentação.

O TAD Tfila implementa uma fila usando vetores. Esta fila é usada para armazenar as consultas de livros.

O TAD Livro é usado pelo sistema para trabalhar com os livros da biblioteca.

O TAD Memoria simula a memória principal do sistema. Cada registro é inserido na memória de forma ordenada. É possível remover o maior ou menor item da memória em $O(1)$.

O TAD Ordenador implementa a ordenação externa usando a técnica de Quicksort Externo.

O TAD TSistemaConsulta armazena dados para consulta de livros.

O TAD TSistemaMotorBusca é responsável pela pesquisa de livros. Ele usa uma árvore binária com um índice para verificar se um livro está na biblioteca, está emprestado ou não está registrado.

O TAD TSistemaManipuladorES é responsável pela leitura e escrita de dados na memória secundária.

Por fim, o TAD Sistema é responsável pelo funcionamento efetivo do sistema, realizando a leitura dos dados, manipulando e escrevendo os resultados em arquivos e na tela.

Programa Principal

O sistema recebe do aviso de comando do usuário cinco variáveis, N, M, E, L e K para efetuar a simulação de gestão de biblioteca. A variável N indica o número de livros da biblioteca, E indica o número de estantes e L indica o número de livros por estante. A variável M indica a capacidade da memória principal do computador e K indica o número de consultas a serem realizadas no sistema.

Em seguida, o aplicativo recebe a listagem dos N livros com a informação se estão emprestados. Cada livro deve ter no máximo 50 caracteres. Estes livros são ordenados e seus nomes salvos num arquivo de texto de nome *livros_ordenados*. Também são gerados arquivos binários representando as estantes da biblioteca. Estantes vazias não são geradas. Cada arquivo recebe o nome *estanteX*, onde x é o identificador da estante e possui os registros dos livros que lá estão armazenados.

A simulação também gera um arquivo-texto chamado *indice* com o registro do primeiro e último livro de cada estante. Estantes vazias são representadas pelo caractere #. O índice é usado para a realização das consultas que serão realizadas a seguir. Se o livro estiver registrado e armazenado em alguma estante, a consulta retorna o identificador da estante e a posição do livro na própria estante.




Figura 4: Inserção de itens em uma árvore de ordem 1.

A consulta também informa se o livro está disponível para empréstimo, se está emprestado ou se não está registrado na biblioteca.

Para executar o programa, digite o seguinte comando:

./tp1

3. Análise de Complexidade

O custo de acessar um registro em memória secundária é algumas ordens de grandeza maior que o custo de processamento na memória principal. Logo, a medida de complexidade aqui está relacionada com o custo para transferir os dados da memória principal e a memória secundária. A ênfase aqui deve ser na minimização do número de vezes que cada registro é transferido entre a memória interna e a memória principal.

Quicksort Externo

A complexidade de melhor caso do quicksort externo é $O(\frac{n}{b})$, em que n é o número de registros a serem ordenados e b é a quantidade de registros lidos por vez na memória secundária. O melhor caso ocorre, por exemplo, em arquivos já ordenados.

O pior caso ocorre quando as chamadas recursivas são árvores degeneradas. Uma partição é vazia e a outra partição é a maior possível. Nesse caso, a complexidade é $O(\frac{n^2}{m})$, onde m é a quantidade de registros que pode ser gravados na memória principal ao mesmo tempo.

A complexidade no caso médio é $O(\frac{n}{b} \log(\frac{n}{m}))$.

Árvore B

Caminhar pela árvore da raiz até uma folha tem um custo igual à sua altura. Numa árvore m -ária cada nó possui, no mínimo, $m+1$ filhos. Assim, o número de nós aumentam exponencialmente em cada nível da árvore. Assim, o custo para pesquisar um registro cresce com o logaritmo base m da ordem da árvore. É possível pesquisar numa árvore de ordem 50 com um milhão de registros com apenas 4 acessos em disco no pior caso.

O custo de inserção de um registro em uma árvore B de ordem m com n registros é também proporcional a $\log_m n$ no pior caso.

Programa principal

As funções de ordenação externa e pesquisa de livros são executadas sequencialmente, logo a medida de complexidade do aplicativo é $O(\frac{n}{b} \log(\frac{n}{m})) + O(\log_m n)$. Logo, a complexidade final é $O(n \log n)$.

4. Análise de Execução

Foram realizados diversos testes para verificar o comportamento do programa conforme a variação da entrada.

No primeiro teste variamos a quantidade de livros, mantendo as demais variáveis constantes.

| | | | | | | |
|-----------|-------|-------|-------|-------|-------|-------|
| Nº livros | 1000 | 2000 | 3000 | 4000 | 5000 | 6000 |
| Tempo (s) | 0.032 | 0.047 | 0.075 | 0.098 | 0.111 | 0.130 |

No segundo teste variamos o tamanho da memória principal, mantendo as demais variáveis constantes.

| | | | | | | |
|-----------|-------|-------|-------|-------|-------|-------|
| Tamanho | 10 | 20 | 30 | 40 | 50 | 60 |
| Tempo (s) | 0.011 | 0.010 | 0.009 | 0.009 | 0.009 | 0.008 |

No terceiro teste variamos o número de estantes, mantendo as demais variáveis constantes.

| | | | | | | |
|-----------|-------|-------|-------|-------|-------|-------|
| Tamanho | 100 | 200 | 300 | 400 | 500 | 600 |
| Tempo (s) | 0.013 | 0.013 | 0.012 | 0.013 | 0.030 | 0.029 |

No quarto teste, variamos o número de livros por estantes, mantendo as demais variáveis constantes.

| | | | | | | |
|-----------|-------|-------|-------|-------|-------|-------|
| Tamanho | 100 | 200 | 300 | 400 | 500 | 600 |
| Tempo (s) | 0.012 | 0.012 | 0.011 | 0.011 | 0.011 | 0.012 |

No último teste, variamos o número de consultas a serem realizadas, mantendo as demais variáveis constantes.

| | | | | | | |
|-----------|-------|-------|-------|-------|-------|-------|
| Tamanho | 100 | 200 | 300 | 400 | 500 | 600 |
| Tempo (s) | 0.052 | 0.053 | 0.069 | 0.072 | 0.073 | 0.075 |

5. Conclusão

A árvore B é simples, de fácil manutenção, eficiente e versátil. Por isso é amplamente utilizada organização de registros em memória secundária como bancos de dados e sistemas de arquivos. Existem, ainda, variações da árvore B, como B* e B+, que ampliam sua utilidade e adicionam novos recursos, como concorrência. Sistemas de paginação de memória virtual pode aumentar sua eficiência em pesquisas de registros.

O Quicksort Externo também é bastante eficiente para ordenação em memória secundária, desde que o pivô seja bem escolhido. Tal como a árvore B, a ordenação é ainda mais eficiente se utilizada com sistema de paginação de memória virtual.

Referências

BAYER, B. AND MC CREIGHT, E. M. 1972. Organization and maintenance of large ordered indices. *Acta Inform.* 1, 173–189.

COMER, D. 1979. The ubiquitous B-tree. *ACM Comput. Surv.* 11, 2, 121–137.

CUNTO, W. GONNET, G. H.. MONARD, M. C. External Quicksort. 1981.

ZIVIANI, N. 2009. Projeto de Algoritmos com Implementações em Pascal e C, 2ª Edição, Editora Cengage Learning.